

CHAPITRE 0:

-série **chronologique=chronique=temporelle**: une suite finie de données quantitatives indexée par le temps.

$$\{y_t\}_{t=1}^T$$

-L'indice temps peut être selon les cas, la seconde, la minute, l'heure, le jour, le mois, l'année, .

-un processus stochastique :

$$\{y_t\}$$

-Une **série temporelle à temps discret**:

une liste de valeurs

prises à des moments précis

et espacées de façon régulière (par exemple chaque jour, chaque mois...)

$$\{(t_1, x_1), (t_2, x_2), \dots (t_n, x_n)\}$$

+Présentations d'une série temporelle:

1. Tableau à deux colonnes

- Colonne 1 : le temps (dates, années...)
 - Colonne 2 : les valeurs observées
- Utile pour analyser les données de façon simple et détaillée.

2. Tableau à plusieurs colonnes (par mois et année)

- Chaque **colonne** représente un mois
- Chaque **ligne** représente une année
- La valeur x_{ij} correspond au mois j de l'année i

Utile pour observer les **variations saisonnières** et comparer les années.

+Étapes de l'analyse d'une série temporelle:

1. Visualisation des données

Représenter les données (graphiques) pour comprendre leur forme générale.

2. Identification des composants

Détecter : tendance, saisonnalité, cycles.

3. Stationnarisation

Transformer la série (ex: différenciation) pour rendre les propriétés stables dans le temps.

4. Choix du modèle et estimation

Choisir un modèle (ex : ARIMA) et calculer ses paramètres.

5. Diagnostic des résidus

Vérifier que les erreurs sont aléatoires (modèle correct).

en d'autres termes :

Préparer: Nettoyer les données

Observer : Comprendre ce qui se passe dans la série

Modéliser: Choisir un modèle mathématique adapté

Prévoir: Utiliser le modèle pour prédire le futur

+Création d'une série temporelle sous R: avec deux classes principales :

1. Classe ts : Utilisée pour des données à intervalles réguliers.

Fonction :

```
serie.ts = ts(valeurs, start=c(2023,1), end=c(2024,1), frequency=1)
```

Paramètres :

- start : date de début
- end : date de fin
- frequency: nombre d'observations par période
 - Annuel = 1
 - Mensuel = 12
 - Trimestriel = 4
 - Hebdomadaire = 52

2. Classe xts

- Extension de zoo, plus flexible
- Permet d'utiliser des dates réelles

Fonction :

```
install.packages("xts")
```

```
library(xts)
```

```
dates = seq(as.Date("2024-01-01"), as.Date("2024-01-10"), by="days")
```

```
serie.xts = xts(valeurs, order.by = dates)
```

Paramètres :

- valeurs : données numériques
- dates : dates associées

CHAPITRE 1: Analyse graphique

1/Le chronogramme est un **graphique linéaire** qui représente une série temporelle:

- Axe horizontal : le **temps (t)**
- Axe vertical : les **valeurs (y_t)**

Le chronogramme permet de :

- Identifier les **tendances, saisonnalités** et **cycles**
- Observer la **dépendance au passé** (corrélation)

En R :

```
plot(serie)
```

Critère	Tendance	Saisonnalité	Périodicité
Définition	Évolution à long terme	Variation régulière liée aux saisons	Variation qui se répète dans le temps
Durée	Long terme	Court terme (année, mois...)	Variable
Répétition	Non	Oui	Oui
Régularité	Continue	Très régulière	Peut être régulière ou non
Lien avec le temps	Général	Fixe (ex : chaque année)	Pas forcément fixe
Exemple	Population augmente	Ventes ↑ en été chaque année	Cycles économiques
Objectif	Voir la direction globale	Détecter effets saisonniers	Identifier cycles répétés

2/Le corrélogramme est un **graphique** qui montre la corrélation entre une série temporelle et ses **valeurs passées (retards)**.

Il permet de mesurer si les valeurs actuelles dépendent des anciennes.

Le corrélogramme sert à :

- Détecter la **dépendance dans le temps**
- Identifier une **périodicité**
- Aider au choix d'un **modèle (ex : ARIMA)**

En R :

```
acf(serie)
```

+Interprétation du corrélogramme:

Axes • Axe horizontal : retards (lags) • Axe vertical : coefficients de corrélation	Interprétation des valeurs • Corrélation ≈ 1 → forte corrélation positive • Corrélation ≈ -1 → forte corrélation négative • Corrélation ≈ 0 → faible corrélation
Lecture du graphique • Chaque barre = corrélation à un retard donné • Lignes pointillées = intervalle de confiance	Analyse des formes • Pics à certains retards → périodicité • Alternance pics/creux → cycles • Corrélation forte → dépendance au passé • Corrélation faible → indépendance

3/Le lag plot est un **graphique** qui montre la relation entre une valeur actuelle et une **valeur passée** d'une série temporelle.

On trace les points : (x_{t-k}, x_t)

Axes • Axe x : valeur passée x_{t-k} • Axe y : valeur actuelle x_t	Cas d'interprétation • Alignement linéaire Forte corrélation → dépendance avec le passé • Dispersion aléatoire Pas de corrélation → indépendance temporelle • Formes spécifiques (courbes, motifs) Relations complexes ou présence de cycles
Ligne → dépendance Nuage → hasard Forme → cycle	

Le lag plot permet de :

- Détecter une **dépendance temporelle**
- Identifier une **saisonnalité ou cycle**
- Repérer des **anomalies (outliers)**

En R :

```
lag.plot(serie, lags = k, layout = c(n, m))
```

- serie : ta série temporelle
- lags = k : nombre de retards (lags) à afficher
- layout = c(n, m) : organisation des graphiques (n lignes, m colonnes)

4/La décomposition est une méthode qui permet de **séparer une série temporelle en plusieurs composantes** pour mieux comprendre son comportement.

Elle permet d'identifier :

- la **tendance** (évolution générale)
- la **saisonnalité** (Comportement qui se répète)
- les **résidus** (Partie aléatoire non expliquée)

Elle aide à analyser la **structure de la série** et à détecter les motifs importants.

5/Le month-plot ou chronogramme par mois: une représentation simultanée des chronogrammes des séries associées à chaque saison.

+Intérêt de la représentation graphique:

La représentation graphique permet d'identifier les principales caractéristiques d'une série temporelle :

Tendance Évolution générale à long terme Donne la direction globale de la série	Variations accidentelles Valeurs anormales (pics ou chutes) Événements exceptionnels
Phénomène périodique (saisonnalité) Variations régulières liées au temps Ex : saisons, fêtes, habitudes	Fluctuations irrégulières Petites variations aléatoires Bruit non expliqué
Cycle Variation répétée mais non régulière Période variable et difficile à prévoir	

CHAPITRE 2: ANALYSE STATISTIQUE

+Indicateurs statistiques:

Moyenne: Donne **la valeur moyenne globale** de la série.

Dispersion (variance / écart-type): Montre **à quel point les valeurs varient** autour de la moyenne.

Si c'est grand → les données sont très dispersées.

+Dépendance dans le temps (Auto-corrélation):

Auto-corrélation: Mesure **le lien entre une valeur et les valeurs passées ou futures**.

Si forte → les valeurs se ressemblent dans le temps

Si faible → pas de relation

Auto-covariance: Même idée que l'auto-corrélation mais en version brute (non normalisée)

Lag (retard): C'est **le décalage dans le temps**

+Exemples de Types de séries :

Bruit blanc: Série totalement aléatoire

- Pas de tendance

- Pas de saisonnalité
- Pas de relation entre valeurs

Marche aléatoire: Chaque valeur dépend de la précédente + hasard

=====

Interprétation simple(ACF et lag plot)

- nuage rond → pas de relation
- nuage en ligne montante → relation positive
- nuage en ligne descendante → relation négative

+Analyse avec auto-corrélation:

Si auto-corrélation proche de 1 → présence de **tendance**

Si elle se répète → présence de **saisonnalité**

+Corrélation croisée:


Permet de mesurer le lien entre **2 séries différentes**

+Modèles de décomposition:

Modèle additif

$$x_t = \underbrace{m_t + S_t}_{\text{partie déterministe}} + \underbrace{Z_t}_{\text{partie aléatoire}},$$


Exemple:



Modèle multiplicatif

$$x_t = \underbrace{m_t \times S_t}_{\text{partie déterministe}} \times \underbrace{Z_t}_{\text{partie aléatoire}}$$

Exemple:




```
random <- rnorm(100)# Générer un bruit blanc(des données aléatoires)

plot.ts(random)# Afficher une série temporelle

# Marche aléatoire

x <- cumsum(random)

# → transforme en série dépendante (chaque valeur dépend de la précédente)

plot.ts(x)# → visualiser la marche aléatoire

lag.plot(x, lags = k)# Lag plot

acf(x)# Auto-corrélation (ACF)

acf(x, lag.max = 10, type = "correlation", plot = FALSE)

# → calcule les corrélations sans afficher

coeff <- acf(AirPassengers, type="correlation", plot=FALSE)

# → récupérer les coefficients d'auto-corrélation

acf(AirPassengers) # Corrélogramme

AP.elec <- ts.intersect(AP, Elect.ts) # Aligner deux séries

plot(AP.elec)# Visualiser deux séries ensemble

plot(as.vector(AP), as.vector(Elect.ts))# Scatter plot entre deux séries

abline(reg = lm(Elec.ts ~ AP))# Ajouter droite de régression

cor(AP, Elect.ts)# Corrélation simple

dec.add <- decompose(AP, type = "additive") # Décomposition additive

dec.mul <- decompose(AP, type = "multiplicative") # Décomposition multiplicative

plot(dec.add)# Visualiser décomposition

names(dec.add)# Voir les éléments
```

CHAPITRE 3: Ajustement d'une série temporelle

+Les types de méthodes:

Méthodes non paramétriques:Exemple : **moyennes mobiles**

Méthodes paramétriques :

- régression linéaire
- modèles ARMA

+Lissage par moyennes mobiles: On remplace chaque valeur par une **moyenne des valeurs autour**

Objectif :

- enlever le bruit
- réduire les variations
- mieux voir la tendance

Objectif	Solution
enlever saisonnalité	grande moyenne
réduire bruit	grande moyenne
garder détails	petite moyenne

+Ajustement de la tendance:

Régression linéaire : On modélise la tendance par une **droite**

Objectif :

- trouver la meilleure droite qui passe proche des points

Méthode utilisée : **moindres carrés** : on minimise l'erreur entre les données et la droite)

Somme des carrés

$$\underbrace{\text{SCT}}_{\text{Variance totale}} = \underbrace{\text{SCR}}_{\text{Variance résiduelle}} + \underbrace{\text{SCE}}_{\text{Variance expliquée}}$$

+Ajustement polynomiale:

Au lieu d'une droite → on utilise une **courbe**

Utile quand :

- la tendance n'est pas linéaire
- la série est plus complexe

+Significativité des paramètres:

Test statistique : On teste si un paramètre est important ou pas

Si **p-value ≤ 0.05** : paramètre important

Si **p-value > 0.05** : paramètre inutile

+Comparaison de modèles:

R^2 (coefficient de détermination) : Mesure la qualité du modèle

proche de 1 $\rightarrow$ bon modèle

proche de 0 $\rightarrow$ mauvais modèle

R^2 ajusté

version améliorée de R^2

+Ajustement de la saisonnalité:

On peut la modéliser avec : des fonctions périodiques (sin / cos) pour capturer les répétitions dans le temps.

```

AP <- AirPassengers # Charger série

length(AP)# Taille de la série

tps <- 1:length(AP)# Créer variable explicative temps

mod1 <- lm(AP ~ tps)# Régression linéaire (tendance)

plot(AP)# Visualiser la série

points(time(AP), fitted(mod1), type="l", col="blue")

# Ajouter la tendance estimée

# → tracer la droite de tendance

summary(mod1)# Résumé du modèle(coefficients, p-value, qualité)

AIC(mod1)# →Critère AIC évalue la qualité du modèle (plus petit = mieux)

mod2 <- lm(AP ~ tps + I(tps^2))# Modèle polynomial (courbe)

summary(mod2)# Résumé modèle polynomial

AIC(mod2)# → comparer avec mod1

MC <- matrix(0, length(AP), 6)# Matrices cosinus pour saisonnalité

MS <- matrix(0, length(AP), 6) # Matrices sinus

mod3 <- lm(AP ~ tps + MC + MS)# Modèle complet (tendance + saisonnalité)

```

CHAPITRE 4: stationnarité

Un **processus stochastique**, c'est un phénomène qui évolue dans le temps avec une part de hasard.

un **bruit blanc**: c'est un processus d'espérance nulle et de variance constante

Une série est dite **stationnaire** si son comportement statistique reste stable dans le temps. cad:

- la moyenne reste stable
- la variance reste stable
- la dépendance entre les valeurs ne change pas selon le moment où on observe la série


+Processus non stationnaire:

Processus à tendance déterministe (TS) : C'est une série qui contient une tendance liée directement au temps.

l'espérance dépend du temps et l'ACF d'une telle série décroît lentement.

Exemple :


- la série monte régulièrement avec le temps
- ou suit une courbe déterminée



Processus à tendance stochastique (DS) : C'est une série où la non-stationnarité vient d'un effet aléatoire accumulé dans le temps.

L'exemple classique est la **marche aléatoire**.

la variance dépend du temps et l'ACF d'une telle série décroît lentement.



+stationnariser une série:

stationnaire = sans tendance + sans saisonnalité

Pour un DS: la **différenciation**

On remplace la série par les différences entre valeurs successives.

Exp : une marche aléatoire devient un bruit blanc après différenciation

Le nombre de différenciations nécessaires s'appelle **l'ordre d'intégration**.

Pour un TS: Il faut:

- estimer la tendance par régression
- calculer les valeurs ajustées
- soustraire cette tendance aux valeurs observées

+Cas d'une tendance polynomiale:

- chaque différenciation réduit le degré de la tendance
- après plusieurs différenciations, on peut supprimer complètement cette tendance
- tendance linéaire → une différenciation peut suffire
- tendance quadratique → il faut souvent deux différenciations

+Cas avec saisonnalité:

Si la série contient :

- une tendance
- et une saisonnalité de période T

alors on peut faire une **différence saisonnière**.

+On vérifie visuellement puis le Test de stationnarité : ADF

- **H0** : la série est non stationnaire
- **H1** : la série est stationnaire
- si **p-value > 0.05** → on garde H0 → série non stationnaire
- si **p-value ≤ 0.05** → on rejette H0 → série stationnaire

+Le bruit blanc et le test de Box-Pierce:

Une fois la série rendue stationnaire, il faut encore vérifier si elle est assimilable à un **bruit blanc** ou non.

- **H0** : pas d'autocorrélation
- **H1** : il existe au moins une autocorrélation
- si **p-value > 0.05** → on accepte H0 → série assimilable à un bruit blanc
- si **p-value ≤ 0.05** → on rejette H0 → la série n'est pas un bruit blanc

```
diff(co2, lag = 12)# calcule la différence entre une valeur et celle 12 périodes avant

diff(co2, lag = 1, differences = 2) # applique 2 différenciations (utile si la tendance est forte)
adf.test(diff(co2, lag = 12))# adf.test()
Box.test(diff(co2, lag = 12))# Box.test()
par(mfrow = c(1,2)) # divise l'écran en 2 graphiques côte à côte

data("AirPassengers") #charge une série déjà existante dans R

x <- numeric(100)# crée un vecteur vide de taille 100
```

CHAPITRE 5: MODÈLE ARMA

+Types de modèles:

Modèle AR(p) (AutoRégressif) : La valeur actuelle dépend des **valeurs passées**

ACF :décroît progressivement

PACF :devient nulle après p

Donc : PACF sert à trouver **p**

Modèle MA(q) (Moving Average) : La valeur actuelle dépend des **erreurs passées**

ACF :devient nulle après q

PACF : décroît progressivement

Donc : ACF sert à trouver **q**

Modèle ARMA(p,q) : combinaison des 2

+Identification du modèle:


Modèle	ACF	PACF
AR(p)	décroît	s'annule après p
MA(q)	s'annule après q	décroît
ARMA(p,q)	décroît	décroît

+Scénarios possibles:

Cas 1 : Pas de dépendance → bruit blanc - rien à modéliser

Cas 2 : Dépendance → modèle ARMA possible

Cas 3 : Série non stationnaire - on doit d'abord faire différenciation



+Choix du modèle:

On teste plusieurs modèles et on compare avec : **AIC on choisit** celui avec le plus petit AIC.

+Méthode Box-Jenkins:

Étapes :

Transformation : rendre la série stationnaire

Identification : analyser ACF et PACF , choisir p et q

Estimation : utiliser arima()

Diagnostic : vérifier si le modèle est bon

Prévision : utiliser le modèle pour prédire

```
pacf(x) # affiche l'auto-corrélation partielle
```

```
AR1 <- arima.sim(list(ar = c(0.8)), n = 1000) # Génère une série dépendante du passé
```

```
acf(AR1)
```

```
model <- arima(x, order = c(1,0,1)) # ajuste un modèle ARMA(1,1)
```


Visuellement	Modèle
stationnaire	ARMA
Non stationnaire +tendance	ARIMA
Non stationnaire +tendance + saisonnalité	SARIMA

ACF	Signification
décroissance lente	non stationnaire
pics réguliers (ex: 12,24)	saisonnalité